REPORTE: Q-LEARNING EN CLIFF WALKING

Alumno : Luis Lara Andrade

Profesor: Victor Uc Cetina

1. Por que el camino de 13 pasos, pegado al acantilado, es optimo?

Es el camino optimo porque representa la distancia mas corta posible entre el inicio S y la meta G dentro de la cuadricula sin cruzar el acantilado. Cada paso ordinario tiene una penalizacion de -1 y no hay descuento de futuro (gamma = 1). Dar 1 paso al norte, 11 pasos al este por la fila 2 y 1 paso al sur hasta la meta suma exactamente 13 pasos, lo que da un retorno acumulado de -13. Cualquier otro camino alternativo que se aleje del acantilado requeriria mas pasos por filas superiores y acumularia una penalizacion mayor (por ejemplo -15 o -17).

2. Por que la curva de entrenamiento queda por debajo de -13 aunque la politica greedy ya sea optima?

Queda por debajo de -13 debido a la exploracion obligatoria del comportamiento epsilon-greedy (con epsilon = 0.1). Durante el entrenamiento, el 10% de las veces el agente toma una accion completamente al azar en lugar de seguir la mejor accion. Como la trayectoria aprendida pasa pegada al borde del acantilado, cualquier eleccion exploratoria accidental hacia el sur hace que el agente caiga al vacio, sumando una fuerte penalizacion de -100 por cada caida. Por esa razon, la recompensa promedio de entrenamiento ronda valores cercanos a -40 o -50, aun cuando los valores de la tabla Q ya aprendieron que la ruta optima otorga -13 al evaluarse sin exploracion (con epsilon = 0).

3. En el paso que cae al acantilado, cual es s' en el backup de Q-learning, y por que ese backup no trata el acantilado como estado terminal?

En el paso que cae al acantilado, el estado siguiente s' es el punto de inicio S, es decir, la coordenada (3, 0).

No se trata como estado terminal porque las reglas del entorno establecen que la caida no finaliza el episodio, sino que simplemente reinicia la posicion del agente en S con una penalizacion de -100 para que continue intentando llegar a la meta. Al ser S un estado no terminal valido, la formula de actualizacion de Q-learning incluye el valor maximo futuro de las acciones disponibles desde el inicio (max Q(S, a')) en lugar de fijar el valor futuro en 0 como se haria unicamente al entrar en la meta G.